

Efektywność estymatorów zmienności opartych na zakresie zmian

Paweł Sakowski

Korefereat do wystąpienia T. Skoczylasa „Modelowanie wariancji finansowych szeregów czasowych przy
użyciu Range-based ARCH uwzględniającego heterogeniczność wariancji”

Konferencja WNE UW
Kazimierz nad Wisłą
27-28/9/2013



UNIwersytet Warszawski
Wydział Nauk Ekonomicznych

Plan prezentacji

1. Efektywność estymatorów zmienności
 - klasyczny estymator zmienności
 - estymator Parkinsona (1980)
 - estymator Osbanda (2007)
 - estymator Garmana-Klassa (1980)
 - estymator Rogersa-Satchella (1991)
2. Uwagi do referatu Tomka Skoczylasa

Założenia ogólne

- logarytm ceny akcji podlega jednowymiarowemu ciągłemu błędzeniu losowemu ze stałą dyfuzji D

Założenia ogólne

- logarytm ceny akcji podlega jednowymiarowemu ciągłemu błędzeniu losowemu ze stałą dyfuzji D
- a zatem, prawdopodobieństwo tego, że logarytm ceny x znajdzie się w przedziale $(x, x + dx)$ w momencie t , zakładając jego początkową wartość x_0 w momencie $t = 0$, wynosi:

$$\left(dx/\sqrt{2\pi Dt}\right) \exp[-(x - x_0)^2/2Dt]$$

Założenia ogólne

- logarytm ceny akcji podlega jednowymiarowemu ciągłemu błędzeniu losowemu ze stałą dyfuzji D
- a zatem, prawdopodobieństwo tego, że logarytm ceny x znajdzie się w przedziale $(x, x + dx)$ w momencie t , zakładając jego początkową wartość x_0 w momencie $t = 0$, wynosi:

$$\left(dx/\sqrt{2\pi Dt}\right) \exp[-(x - x_0)^2/2Dt]$$

- porównując to z rozkładem normalnym, zauważamy, że D jest wariancją zmiany logarytmu ceny $(x - x_0)$ w interwale jednostowym

Klasyczny estymator zmienności

Tradycyjny sposób estymacji wariancji D :

Klasyczny estymator zmienności

Tradycyjny sposób estymacji wariancji D :

- obserwujemy $x(t)$ w momentach $t = 0, 1, 2, 3, \dots, n$

Klasyczny estymator zmienności

Tradycyjny sposób estymacji wariancji D :

- obserwujemy $x(t)$ w momentach $t = 0, 1, 2, 3, \dots, n$
- definiujemy d_t jako zmiany w t -tym interwale:

$$d_t = x(t) - x(t-1), \quad t = 1, 2, 3, \dots, n$$

Klasyczny estymator zmienności

Tradycyjny sposób estymacji wariancji D :

- obserwujemy $x(t)$ w momentach $t = 0, 1, 2, 3, \dots, n$
- definiujemy d_t jako zmiany w t -tym interwale:
 $d_t = x(t) - x(t-1)$, $t = 1, 2, 3, \dots, n$
- obliczamy wyrażenie:

$$D_x = \frac{1}{n-1} \sum_{t=1}^n (d_t - \bar{d})^2$$

gdzie

$$\bar{d} = \frac{1}{n} \sum_{m=1}^n d_m$$

Klasyczny estymator zmienności

Tradycyjny sposób estymacji wariancji D :

- obserwujemy $x(t)$ w momentach $t = 0, 1, 2, 3, \dots, n$
- definiujemy d_t jako zmiany w t -tym interwale:
 $d_t = x(t) - x(t-1)$, $t = 1, 2, 3, \dots, n$
- obliczamy wyrażenie:

$$D_x = \frac{1}{n-1} \sum_{t=1}^n (d_t - \bar{d})^2$$

gdzie

$$\bar{d} = \frac{1}{n} \sum_{m=1}^n d_m$$

- dla niskiej liczby obserwacji estymator ten ma małą precyzję!

Klasyczny estymator zmienności

Tradycyjny sposób estymacji wariancji D :

- obserwujemy $x(t)$ w momentach $t = 0, 1, 2, 3, \dots, n$
- definiujemy d_t jako zmiany w t -tym interwale:
 $d_t = x(t) - x(t-1)$, $t = 1, 2, 3, \dots, n$
- obliczamy wyrażenie:

$$D_x = \frac{1}{n-1} \sum_{t=1}^n (d_t - \bar{d})^2$$

gdzie

$$\bar{d} = \frac{1}{n} \sum_{m=1}^n d_m$$

- dla niskiej liczby obserwacji estymator ten ma małą precyzję!
 - zmienność zrealizowana (Andersen *et al.* 2001),
 - modele z rodziny GARCH (Engle 1982, Bollerslev 1986 i następni)


Symulacja Monte Carlo

- ścieżka cen $x(t)$ składa się z $n = 10000$ interwałów, $t = 1, 2, \dots, 10000$
- ciągłe stopy zwrotu mają rozkład normalny:


$$\log [x(t)] - \log [x(t-1)] \sim N(0, 0.001^2)$$

- liczba powtórzeń symulacji = 10000


Błądzenie losowe



Błądzenie losowe




Błądzenie losowe




Błądzenie losowe




Błądzenie losowe




Błądzenie losowe




Błądzenie losowe




Błądzenie losowe




Błądzenie losowe



Błądzenie losowe



Symulowany rozkład klasycznego estymatora zmienności



Estymator D_l Parkinsona (1980)

- zamiast mierzyć $x(n)$ dla $n = 0, 1, 2, 3, \dots$ obserwujemy różnicę l między logarytmami maksymalnej i minimalnej ceny wewnątrz danego interwału

$$\hat{\sigma}_P^2 = \frac{1}{4 \log 2} (\log H_t - \log L_t)^2$$

gdzie H_t i L_t to odpowiednio ceny maksymalne i minimalne.

Estymator D_l Parkinsona (1980)

- zamiast mierzyć $x(n)$ dla $n = 0, 1, 2, 3, \dots$ obserwujemy różnicę l między logarytmami maksymalnej i minimalnej ceny wewnątrz danego interwału

$$\hat{\sigma}_P^2 = \frac{1}{4 \log 2} (\log H_t - \log L_t)^2$$

gdzie H_t i L_t to odpowiednio ceny maksymalne i minimalne.

- intuicja: taki zakres powinien być bardziej efektywnym pomiarem wariancji, w porównaniu ze zmianą ceny między dwoma arbitralnie wybranymi miejscami w czasie (tj. początkiem i końcem danego interwału).

Estymator D_l Parkinsona (1980)

- Rozkład i własności zakresu zmian l są znane. Zachodzi m. in.:

$$E[l^p] = \frac{4}{\sqrt{\pi}} \Gamma\left(\frac{p+1}{2}\right) \left(1 - \frac{4}{2^p}\right) \zeta(p-1) (2Dt)^{p/2}$$

gdzie $p \geq 1$, a $\zeta(x)$ jest funkcją zeta Riemanna.

- zaś w szczególności mamy:

$$E[l] = \sqrt{8Dt/\pi}$$

oraz

$$E[l^2] = (4 \log 2) Dt$$

Estymator D_l Parkinsona (1980)

- dla interwału jednostkowego zachodzi także:

$$D = 0.393(E[l])^2 = 0.361E[l^2]$$

- mamy zatem relację:

$$E[l^2] = 1.09(E[l])^2$$

która jest wygodna przy testowaniu tego, czy obserwowane zakresy zmian l pochodzą z procesu błędzenia losowego

- w rezultacie, mając zbiór zakresów zmian (l_1, l_2, \dots, l_n) obserwowanych w n jednostkowych interwałach, estymatorem wariancji D jest:

$$D_l = \frac{0.361}{n} \sum_{i=1}^n l_i^2$$

porównanie estymatorów D_x i D_l

- wariancja estymatora D_x

$$E[(D_x - D)^2] = \left[\frac{E(x^4)}{E(x^2)} - 1 \right] \frac{D^2}{N_x} = \frac{2D^2}{N_x}$$

- wariancja estymatora D_l


$$E[(D_l - D)^2] = \left[\frac{E(l^4)}{E(l^2)} - 1 \right] \frac{D^2}{N_l} = \frac{0.41D^2}{N_l}$$

- A zatem, wariancje estymatorów zbliżone jeśli zachodzi:

$$N_x \approx 5N_l$$

co oznacza, że stosując D_l zamiast D_x możemy zredukować liczbę obserwacji o ok. **80%** zachowując tę samą precyzję estymatora!

Symulowany rozkład estymatora Parkinsona (1980)



Inne estymatory oparte na zakresie zmian

- Estymator Osbanda (2007)

$$\hat{\sigma}_{\text{Osb}}^2 = 0.84(\log H_t - \log L_t) - \\ - 0.39|\log C_t - \log O_t|$$

gdzie O_t i C_t to odpowiednio ceny otwarcia i zamknięcia w interwale t .

Inne estymatory oparte na zakresie zmian

- Estymator Osbanda (2007)

$$\hat{\sigma}_{\text{Osb}}^2 = 0.84(\log H_t - \log L_t) - \\ - 0.39|\log C_t - \log O_t|$$

gdzie O_t i C_t to odpowiednio ceny otwarcia i zamknięcia w interwale t .

- Estymator Garmana-Klassa (1980)

$$\hat{\sigma}_{\text{GK}}^2 = 0.5[\log H_t - \log L_t]^2 - \\ - (2 \log 2 - 1)[\log C_t - \log O_t]^2$$

Inne estymatory oparte na zakresie zmian

- Estymator Osbanda (2007)

$$\hat{\sigma}_{\text{Osb}}^2 = 0.84(\log H_t - \log L_t) - 0.39|\log C_t - \log O_t|$$

gdzie O_t i C_t to odpowiednio ceny otwarcia i zamknięcia w interwale t .


- Estymator Garmana-Klassa (1980)

$$\hat{\sigma}_{\text{GK}}^2 = 0.5[\log H_t - \log L_t]^2 - (2 \log 2 - 1)[\log C_t - \log O_t]^2$$


- Estymator Rogersa & Satchella (1991)

$$\hat{\sigma}_{\text{RS}}^2 = \log(H_t/O_t)[\log(H_t/O_t) - \log(C_t/O_t)] + \log(L_t/O_t)[\log(L_t/O_t) - \log(C_t/O_t)]$$


Symulowany rozkład estymatora Osbanda (2007)



Symulowany rozkład estymatora Garmana-Klassa (1980)



Symulowany rozkład estymatora Rogersa-Satchella (1991)



Statystyki próbkowe estymatorów zmienności

prawdziwa wartość $\sigma^2 = 1.0 \times 10^{-6}$

	średnia $\times 10^6$	odch. std. $\times 10^6$	odch. std. do klasycznego	redukcja obs.
klasyczny	1.02	1.44	-	-
Parkinson	0.99	0.65	45%	79.8%
Osband	1.11	0.57	40%	84.2%
Garman-Klass	0.99	0.52	37%	87.9%
Rogers-Satchell	0.99	0.57	40%	84.2%

Uwagi do referatu Tomka Skoczylasa

- Czy model RHARCH może być szacowany za pomocą powszechnie dostępnych pakietów statystycznych?
- Czy MSE prognoz różnią się istotnie od siebie?
Warto rozważyć raportowanie odch. std. miar MSE.
- Jak zdefiniowana jest miara QLIKE?
- Błędy w oznaczeniach w równaniach?
Model RGARCH(1,1)

$$r_t = \mu + \varepsilon_t$$

$$\varepsilon_t \sim N\left(0, \frac{1}{4 \log 2} \lambda_t^2\right) \quad \sigma_P^2 = \frac{1}{4 \log 2} \left(\log(H_t/L_t)\right)^2$$

$$\lambda_t = \omega + \alpha R_{t-1} + \beta \lambda_{t-1}$$

$$R_{t-1} = \log(H_{t-1}/L_{t-1}) \stackrel{?}{=} \lambda_{t-1}$$

Dziękuję!

Paweł Sakowski
`sakowski@wne.uw.edu.pl`